

Pokec-z — fairness multi-axes par composition post-hoc

Mini-projet IADATA708. Branche `feature/fairgnn-fix-and-multi-fairness`.

1. Protocole expérimental

Données. Pokec-z (subset officiel FairGNN, *Žilinský kraj*) : 66 569 nœuds, ~729 k arêtes dirigées, 264 features tabulaires. Reproduction cross-dataset sur **Pokec-n** (~67 k nœuds, 883 k arêtes). Cible : `completed_level_of_education_indicator` (binaire, 47.7 % positif, sélectionnée par sweep multi-seed parmi 8 candidates). Attributs sensibles : `gender`, `region` (binaires), `age_group` (young/adult/senior), plus les intersections `gender × age_group` et `gender × region` — pour sortir du mono-axe (Crenshaw 1989).

Splits & seeds. Stratifié `y × gender` 60/20/20 ; multi-seed [3, 7, 21, 42, 99] agrégé en `mean ± std`.

Méthodes (5 familles) :

- *Baselines* : GraphSAGE (2 SAGE, hidden=256, dropout=0.5), TabICL (foundation tabulaire INRIA 2025, no graph, frozen).
- *Pre-process* : Resampling, FairDrop (intra-group), Reweighting Kamiran-Calders 2012.
- *In-training* : **FairGNN avec Gradient Reversal Layer** (Ganin 2015) — réimplémentation propre de Dai & Wang 2021. La version originale combinait `l_cls - λ · l_adv` dans un seul optimiseur, ce qui n'est pas du min-max et collapsait `F1 = 0.4834` à certains `λ`.
- *Post-process* : EOT (Hardt 2016), DPT (variante Demographic Parity), composite DPT cellulaire, INLP (Ravfogel 2020) sur embeddings et features, et **les compositions INLP+DPT** — clé du finding.

Métriques. `ADP`, `ΔEO`, `AUC gap` (sortie), *Sensitive Leakage AUC* (probe LR train→test, balanced sampling). Garde-fous : ruff propre, 50+ tests pytest, no-pandas/no-loops enforced.

2. Résultats clés

Sur Pokec-z : `r(gender)` = -0.046 (homophilie quasi-nulle) mais `r(region)` = 0.901. Le graphe **n'est pas** homophile sur l'attribut sensible direct.

Méthode (seed=42)	F1	ADP gender	Leakage gender
GraphSAGE	0.938	0.043	0.81
TabICL	0.948	0.041	0.88
FairGNN(λ=5.0, GRL)	0.853	0.009	0.86
TabICL+DPT@gender	0.945	0.004	0.88
TabICL+DPT_composite	0.941	0.001	0.88
TabICL+INLP+DPT@gender	0.943	0.002	0.71
TabICL+INLP+DPT_composite ★	0.866	0.011	0.50

Trois findings non-triviaux :

1. **TabICL bat GraphSAGE en F1 brut** (0.948 vs 0.938) — l'inverse de la narrative dominante. Sur ce dataset, le graphe n'apporte rien à la prédiction. Cohérent avec `r(target) ≈ 0`.
2. **Une chaîne post-hoc pareto-domine le gold-standard in-training.** FairGNN(λ=5.0) sacrifie 9 pp de F1 pour `ADP=0.009` ; TabICL+DPT@gender atteint `ADP=0.004` à `F1=0.95` — strictement meilleur sur les deux axes, sans aucun retraining.
3. **L'ULTIMATE combo** TabICL+INLP_composite+DPT_composite atteint le leakage **chance level (0.50 ± 0.01)** sur les **5 axes simultanément**, `ADP < 0.05` partout, à 8 pp de F1. La même chaîne sur GraphSAGE collapse à `F1=0.59` — le GNN avait tellement encodé le sensible (via `r(region)=0.9`) qu'INLP détruit la représentation.




Fig 1. Pareto F1 vs ΔDP sur l'axe gender. TabICL+DPT_comp domine en haut-gauche ; FairGNN($\lambda=5$) Pareto-dominé.




Fig 2. Leakage AUC sur 5 axes sensibles. Les méthodes INLP_composite (2 dernières lignes) atteignent uniformément le chance level (0.50, vert) sur les 5 axes ; les autres laissent leakage > 0.6 partout.

3. Compromis performance $\leftrightarrow$ équité $\leftrightarrow$ robustesse

Compromis principal documenté : **performance vs équité** (Fig 1). Trois points clés.

- **Pas de free-lunch sur fairness multi-axes.** Le single-axis (DPT@gender, INLP@gender) atteint ΔDP gender quasi-nul mais laisse ΔDP gender $\times$ age à 0.10 — *whack-a-mole intersectionnel*, Crenshaw 1989 rendu empirique.
- **Composer les axes coûte du F1.** ULTIMATE combo perd 8 pp pour satisfaire les 5 axes ensemble — inévitable sous Chouldechova-Kleinberg 2017 dès que les taux de base diffèrent.
- **Robustesse aux perturbations.** La baseline GraphSAGE est robuste à un bruit features $\sigma \leq 0.3$ et edge drop $\leq 30\%$ (Section 7 du repo amont, héritée). La chaîne post-hoc **préserve** cette robustesse : elle ne touche pas l'encoder.

4. Validation et limites

Validation forte. Reproduction sur **Pokec-n** : tous les chiffres clés se reproduisent à écart < 0.01 ; ranking des méthodes strictement identique. Multi-seed [3, 7, 21, 42, 99] : std < 0.02 sur le leakage. Calibration Guo 2017 testée : T = 1.020 sur GraphSAGE $\rightarrow$ no-op, l'objection « calibration différentielle » ne tient pas.

Limites principales — (1) *mono-dataset family* : Pokec-z $\approx$ Pokec-n, deux subsets du même réseau slovaque (Bail/Credit re-graphifiés nécessaires pour un workshop paper) ; (2) *probe linéaire* : INLP garantit l'invariance contre un classifieur linéaire ; un MLP pourrait recouvrir du signal résiduel ; (3) *pré-traitement implicite* : INLP sur x brut côté TabICL = pré-traitement de l'input (côté GraphSAGE c'est purement post-hoc sur embeddings) ; (4) *sémantique opaque* : region=0/1 binarisé sans documentation par les auteurs FairGNN ; (5) *catégories réifiées* : la fairness ML opère par agrégation de catégories préalables, *historiquement contingentes* (Hoffmann 2019). Une fairness individuelle (Dwork 2012) sortirait de ce périmètre.

Outils d'IA (mention exigée) : assistance algorithmique pour la réimplémentation FairGNN-GRL, la migration pandas $\rightarrow$ polars, TabICL, INLP / calibration / reweighting, et la rédaction. Code revu, testé, exécuté par les auteurs.

Références. Hardt-Price-Srebro 2016 ; Ravfogel et al. 2020 ; Ganin & Lempitsky 2015 ; Dai & Wang 2021 ; Kamiran & Calders 2012 ; Newman 2003 ; Chouldechova 2017 ; Crenshaw 1989 ; Hoffmann 2019 ; Qu et al. 2025 ; Laclau et al. 2024.