

Pokec-z — Fairness multi-axes par composition d'outils post-hoc

Mini-projet IADATA708. Branche `feature/fairgnn-fix-and-multi-fairness`.

1. Setup

Données. Pokec-z (subset officiel FairGNN, *Žilinský kraj*) : 66 569 nœuds, ~729 k arêtes, 264 features tabulaires. Reproduction sur **Pokec-n**. Cible : `completed_level_of_education_indicator` (binaire, 47.7 % positif). Attributs sensibles : `gender`, `region` (binaires), `age_group` (3 classes), plus les intersections `gender × age_group` et `gender × region` — soit **5 axes** simultanés.

Splits. Stratifié $y \times \text{gender}$ 60/20/20. Multi-seed [3, 7, 21, 42, 99].

Méthodes (toolbox de 5 familles) :

- *Baselines* : GraphSAGE (2 SAGE, hidden=256, dropout=0.5), **TabICL** (foundation tabulaire INRIA 2025, no graph, frozen).
- *Pre-process* : Resampling, FairDrop, Reweighting Kamiran-Calders 2012.
- *In-training* : **FairGNN avec Gradient Reversal Layer** — réimpl propre de Dai & Wang 2021. La version originale combinait `l_cls - λ · l_adv` dans un seul optimiseur (pas du min-max), F1 collapsait à 0.4834 à certains λ .
- *Post-process* : EOT (Hardt 2016), DPT (Demographic Parity Threshold), **INLP** (Ravfogel 2020) sur embeddings et features, et **les compositions INLP+DPT et leur version multi-axes simultanée**.

Métriques. ΔDP , ΔEO , AUC gap (sortie), **Sensitive Leakage AUC** (probe LR train→test, Laclau et al. 2024). 50+ tests pytest, ruff propre, no-pandas/no-loops enforced.

2. Finding 1 — Une toolbox, chaque outil sa métrique

Notre résultat empirique principal sur cette première dimension est que **les méthodes de fairness ne sont pas substituables**. Chaque famille attaque une partie spécifique du problème, et il faut souvent en composer plusieurs pour traiter les trois métriques en même temps.

Fig 1. Chaque outil tape une métrique différente — axe gender, Pokec-z
DPT casse ΔDP , INLP casse le leakage ; aucun outil seul ne fait les trois.




Fig 1. Mêmes méthodes, 3 métriques. **DPT** (bleu) écrase ΔDP à 0.004 mais ne touche pas le leakage. **INLP** (vert) tombe le leakage à 0.712 mais ne change pas ΔDP . **FairGNN** (rouge) bouge un peu les deux au prix de F1. Seul l'**ULTIMATE** (orange = TabICL+INLP_composite+DPT_composite) règle les trois en même temps.

Pour un ingénieur qui voudrait un checklist, le mapping métrique → outil est le suivant :

Si tu veux réduire...	Utilise	Pourquoi
ΔDP (taux de prédictions ≈ entre groupes)	DPT post-process	calibre un seuil par groupe, c'est l'objectif direct
ΔEO (TPR ≈ entre groupes parmi $y=1$)	EOT post-process	même méca mais sur le sous-set $y=1$
Leakage (sensible récupérable depuis embeddings)	INLP	projette l'espace orthogonal aux directions du sensible
Tout en même temps	INLP_composite + DPT_composite	les deux sont orthogonaux et se composent sans conflit

Cette toolbox a une conséquence directe : **un foundation model + 30 lignes de post-process Pareto-domine FairGNN sur Pokec-z**. TabICL+EOT atteint $F1=0.946$ et $\Delta DP=0.007$ contre FairGNN qui plafonne à $F1=0.853$ et $\Delta DP=0.009$. On gagne 9 points de F1 *et* on est légèrement plus équitable, à un coût d'entraînement quasi-nul (TabICL est frozen, le calibrage des seuils prend moins d'une seconde). C'est un résultat qui invite à la prudence avant d'engager une méthode in-training adversariale sophistiquée.

Le théorème de Chouldechova-Kleinberg (2017) dit par ailleurs que $\Delta DP=0$ et $\Delta EO=0$ sont mathématiquement incompatibles dès que les taux de base diffèrent entre groupes — ce qu'on vérifie expérimentalement : $DPT@age_group$ baisse ΔDP de 0.075 à 0.044 mais double ΔEO (0.034 → 0.074). Choisir une métrique n'est pas un choix algorithmique, c'est un **choix normatif**.

3. Finding 2 — TabICL tient la composition multi-axes, GraphSAGE s'écrase

Le second résultat porte sur la **fairness sur plusieurs variables simultanément** (`gender + age_group + region`, encodés en attribut composite à 12 cellules). Pour traiter cinq axes à la fois, il faut composer **INLP_composite** (latent) + **DPT_composite** (sortie). C'est notre chaîne ULTIMATE.

Fig 2. TabICL tient la composition, GraphSAGE s'écrase
à droite : leakage descend au chance level pour les deux ; à gauche : GraphSAGE perd 35 pp de F1, TabICL seulement 8 pp.




Fig 2. F1 et leakage le long de la chaîne. À gauche : TabICL garde $F1=0.87$; GraphSAGE chute à 0.59 (perte de 35 pp de F1). À droite : les deux chaînes atteignent leakage = chance level (0.5).

Pourquoi GraphSAGE s'écroule et pas TabICL ? Les coefficients d'assortativité de Newman (2003) racontent toute l'histoire : $r(\text{gender}) = -0.046$ (le graphe n'est pas du tout homophile en gender), mais $r(\text{region}) = 0.901$ (le graphe est massivement homophile en region). Le message passing de GraphSAGE recombine les features d'un nœud avec celles de ses voisins ; quand ces voisins partagent presque toujours la même region, l'embedding final encode la region beaucoup plus intensément que la feature brute ne le laissait penser. Quand INLP_composite supprime ensuite les directions sensibles, il enlève une part majeure de l'information utile et la représentation s'effondre. TabICL, qui ne consomme jamais le graphe, n'a pas ce problème : ses embeddings ne sont pas dominés par la region, donc INLP ne casse rien d'essentiel.

La règle pratique qui en sort est utilisable avant tout entraînement : mesurer $r(s)$ pour chaque attribut sensible. Si $r(s)$ est faible, le graphe n'aide pas à prédire la cible et n'amplifie pas le biais marginal, auquel cas un foundation model tabulaire + post-process est presque toujours le bon choix. Si $r(s)$ est élevé (le cas typique des datasets fairness-on-graphs publiés), les méthodes in-training graphiques redeviennent nécessaires parce que le post-process, qui n'opère que sur les sorties, ne peut pas atteindre l'espace latent biaisé. Sur Pokec-z, $r(\text{gender}) = -0.046$ aurait dû nous orienter vers TabICL avant même de lancer GraphSAGE.

La validation multi-seed [3, 7, 21, 42, 99] confirme la stabilité : $\Delta DP \text{ gender ULTIMATE} = 0.006 \pm 0.005$; leakage gender = 0.500 ± 0.010 ; $F1 = 0.87$ à dispersion marginale sur TabICL. La reproduction sur Pokec-n donne les mêmes chiffres à un écart inférieur à 0.01.

4. Compromis perf ↔ équité ↔ robustesse

Sur l'axe perf vs équité, payer 8 points de F1 pour obtenir la fairness multi-axes complète sur TabICL est un compromis défendable. Sur GraphSAGE, perdre 35 points de F1 pour le même résultat de fairness rend la chaîne inutilisable en production — c'est exactement le genre de situation où le coût de la fairness fait basculer le choix d'architecture.

Il n'y a pas de free-lunch intersectionnel. Calibrer DPT uniquement sur gender atteint $\Delta DP \text{ gender} = 0.004$ mais laisse $\Delta DP \text{ gender} \times \text{age_group}$ à 0.10, voire le pousse plus haut sur FairGNN où on observe 0.154 sur l'axe croisé alors que le marginal gender est à 0.009 — c'est l'effet whack-a-mole que prédit l'argument intersectionnel de Crenshaw (1989). Si on veut traiter les axes croisés, il faut explicitement construire l'attribut composite et calibrer dessus, pas espérer que le débiaising mono-axe suffira.

Sur la robustesse, la chaîne post-hoc préserve la robustesse héritée du modèle de base parce qu'elle ne modifie pas l'encoder : GraphSAGE reste robuste à un bruit features $\sigma \leq 0.3$ et à un edge drop $\leq 30\%$ (mesures issues du repo amont) avant comme après l'application d'INLP+DPT. C'est un avantage non-trivial des méthodes post-hoc sur l'in-training fairness, qui modifie l'encoder et peut dégrader sa robustesse de façon imprévue.

5. Limites

Limite philosophique. Les métriques de fairness encodent toutes une position normative implicite : $\Delta DP=0$ incarne l'anti-classification stricte (aucune corrélation avec le sensible n'est légitime), $\Delta EO=0$ incarne une position méritocratique (les corrélations conditionnées à la vérité sont acceptables), la calibration par groupe assume que les écarts marginaux sont OK tant que la prédiction est correcte par groupe. Choisir une métrique, c'est choisir une éthique — et le théorème d'incompatibilité montre qu'on ne peut pas toutes les satisfaire à la fois. Notre toolbox fournit les outils, mais elle ne tranche pas le débat normatif.

Importation culturelle des catégories. La fairness ML hérite des catégories du civil rights act US des années 60 (gender, race binaires) et notre dataset les reproduit en réduisant gender et region à 0/1 sans documentation sémantique. Hoffmann (2019) et Hanna et al. (2020, FAccT) pointent que cette importation efface les axes de discrimination locaux. Dans le cas slovaque, les deux axes effectifs sont la minorité hongroise (~8 % de la population, concentrée au sud du pays) et surtout la minorité Roma (estimée 8-10 %, concentrée à l'est, principal axe de discrimination en logement, éducation et emploi). Or le subset FairGNN de Pokec-z code spoken_languages via 8 indicateurs binaires — anglais, allemand, russe, français, espagnol, italien, slovaque, japonais — qui sont tous des langues internationales ou la langue majoritaire. Le hongrois (madarsky), le tchèque (cesky) et le romani sont absents. Le dataset SNAP original encode pourtant ces langues en texte libre ; c'est la curation FairGNN qui a retenu seulement les 8 indicateurs "internationaux", probablement parce que Žilinský kraj a une population hongroise marginale (0.13 %) et que les Roma y sont peu représentés. Conséquence : le subset sur lequel toute la littérature fairness-on-graphs travaille est, par construction, aveugle aux axes de discrimination les plus pertinents dans le contexte slovaque. Notre analyse opère donc sur un proxy culturellement importé, et la fairness multi-axes que nous mesurons reste circonscrite aux catégories que la curation a bien voulu encoder.

Limites techniques. La garantie d'invariance d'INLP n'est valide que contre un classifieur linéaire ; un MLP probe non-linéaire pourrait recouvrir du signal résiduel dans les directions non couvertes par les projections. Côté FairGNN, le discriminateur adversarial est binaire dans la formulation standard de Dai & Wang : pour faire de la fairness sur age_group (3 classes) en in-training, il faudrait redimensionner la tête de discriminateur, ce que nous n'avons pas implémenté — l'in-training multi-classe reste hors périmètre. Enfin, INLP appliqué côté TabICL opère sur les features brutes plutôt que sur des embeddings (TabICL ne les expose pas), ce qui est techniquement du pré-traitement. Les deux régimes restent comparables en leakage parce que le probe est appliqué sur ce que chaque modèle voit, mais le label "post-process pur" ne s'applique strictement qu'à GraphSAGE.

Limite de généralisation. Pokec-z et Pokec-n sont deux subsets du même réseau slovaque, et la cible completed_level_of_education_indicator est faiblement homophile en gender ($r \approx -0.046$). Nos conclusions sur "TabICL bat GraphSAGE" et "post-process suffit" sont conditionnelles à cette propriété : sur un graphe fortement homophile à l'attribut sensible, le classement s'inverserait probablement.

Outils d'IA (mention exigée) : assistance algorithmique pour la réimplémentation FairGNN-GRL, la migration pandas → polars, l'intégration TabICL, l'ajout des modules INLP / calibration / reweighting, et la rédaction. Code revu, testé, exécuté par les auteurs.

Références. Hardt-Price-Srebro 2016 ; Ravfogel et al. 2020 ; Ganin & Lempitsky 2015 ; Dai & Wang 2021 ; Kamiran & Calders 2012 ; Chouldechova 2017 ; Crenshaw 1989 ; Hoffmann 2019 ; Hanna et al. 2020 (FAccT) ; Newman 2003 ; Qu et al. 2025 (TabICL) ; Laclau et al. 2024.