

Pokec-z — Quel outil pour quelle métrique, sur quel axe ?

Mini-projet IADATA708. Branche `feature/fairgnn-fix-and-multi-fairness`.

1. Setup

Données. Pokec-z (subset officiel FairGNN, *Žilinský kraj*) : 66 569 nœuds, ~729 k arêtes, 264 features tabulaires.

Cible. `completed_level_of_education_indicator` (binaire, 47.7 % positif). **Attributs sensibles** : `gender`, `region` (binaires), `age_group` (3 classes), plus les intersections `gender × age_group` et `gender × region` — soit **5 axes** simultanés.

Splits. Stratifié `y × gender` 60/20/20. Multi-seed [3, 7, 21, 42, 99].

Méthodes :

- *Baseline* : GraphSAGE (2 SAGE, hidden=256, dropout=0.5).
- *Pre-process* : Resampling, FairDrop, Reweighting Kamiran-Calders 2012.
- *In-training* : **FairGNN** (Dai & Wang 2021), méthode adversariale, entraînement two-optimizer alternant canonique.
- *Post-process* : **EOT** (Hardt 2016, ΔEO), **DPT** (ΔDP), **INLP** (Ravfogel 2020, leakage sur embeddings), composition mono-axe **INLP+DPT**, et la chaîne composite multi-axes **INLP_composite + DPT_composite** sur l'attribut joint à 12 cellules.

Métriques. ΔDP , ΔEO , AUC gap (sortie), **Sensitive Leakage AUC** (probe LR train→test, Laclau et al. 2024). 50+ tests pytest, ruff propre, no-pandas/no-loops enforced.

2. Finding 1 — La toolbox post-process bat FairGNN sur la fairness

Premier résultat : les méthodes de fairness ne sont pas substituables. Chaque famille de post-process attaque **une partie spécifique** du problème, et FairGNN ne fait ni l'une ni l'autre proprement.

Méthode	ΔDP gender	Leakage gender
GraphSAGE baseline	0.043	0.812
FairGNN (canonical, two-optimizer)	0.030	0.828
GraphSAGE+EOT@gender	0.019	0.812
GraphSAGE+DPT@gender	0.019	0.812
GraphSAGE+INLP@gender	0.043	0.573
GraphSAGE+INLP+DPT@gender	0.003	0.573

À F1 essentiellement équivalent (~0.94 dans tous les cas, dispersion multi-seed dans le bruit), les chaînes post-process atteignent :

- **DPT/EOT** (seuil par groupe) → réduit $\Delta DP/\Delta EO$ 2× à 4× vs FairGNN, sans toucher aux embeddings (leakage inchangé).
- **INLP** (projection sur embeddings) → réduit le leakage 0.81 → 0.57, sans toucher aux seuils (ΔDP inchangé).
- **INLP+DPT** : l'un opère sur les embeddings, l'autre sur les seuils, les deux opérations sont orthogonales et se composent sans conflit. Résultat : $\Delta DP=0.003$ ET leakage=0.57 — **10× mieux** que FairGNN sur ΔDP , **24 pp** de leakage en moins.

Pourquoi FairGNN reste partiel. L'encoder apprend à tromper un adversaire MLP spécifique sans supprimer le signal sous-jacent. Un autre probe (la LR de notre métrique de leakage) peut encore l'extraire. L'in-training adversariale donne une garantie *empirique* contre un adversaire spécifique ; INLP donne une garantie *formelle* contre toute attaque linéaire.

Le théorème de Chouldechova-Kleinberg (2017) confirme par ailleurs l'incompatibilité de $\Delta DP=0$ et $\Delta EO=0$ dès que les taux de base diffèrent : **DPT@age_group** baisse ΔDP de 0.075 à 0.044 mais double ΔEO . **Choisir une métrique, c'est choisir une éthique.**

3. Finding 2 — Le bon axe à débiaiser = celui que le graphe amplifie

Le second résultat est méthodologique et **inverse l'intuition initiale**. On a passé l'essentiel du projet à débiaiser `gender` (axe protégé reconnu). Mesurer le coefficient d'assortativité de Newman (2003) sur les 3 axes sensibles révèle qu'on s'est trompé d'axe :

Axe	$r(s)$	Interprétation
gender	-0.046	graphe quasi-aléatoire vs gender → message passing n'amplifie rien
age_group	+0.352	légère homophilie générationnelle
region	+0.901	graphe massivement homophile en region

$r(\text{region}) = 0.9$ signifie que ~90 % des arêtes connectent deux personnes de la même région : Pokec-z est en pratique un graphe de régions, faiblement inter-connecté. Un GNN va amplifier cette structure dans ses embeddings — *c'est exactement le scénario où les méthodes fairness-on-graphs sont conçues pour intervenir*. Or notre setup typique applique FairGNN avec l'adversaire sur `gender`, là où le graphe ne fait quasiment rien.

Test empirique : FairGNN avec adversaire sur `region` (multi-seed Pokec-z) au lieu de `gender` :

Adversaire	F1	ΔDP region	Leakage region
FairGNN(adv=gender, $\lambda=5$)	0.853	0.073	0.666
FairGNN(adv=region)	0.937	0.033	0.761 ← <i>augmente</i>
GraphSAGE+DPT@region	0.939	0.025	0.641
GraphSAGE+INLP+DPT@region	0.932	0.020	0.524

Cibler le bon axe (`region`) avec FairGNN récupère le F1 et réduit modérément ΔDP , mais **augmente le leakage** : l'encoder trompe le MLP adversaire sans nettoyer la représentation. **Post-process simple bat FairGNN sur les 3 métriques même quand FairGNN cible le bon axe.**

Règle pratique : mesurer $r(s)$ avant tout entraînement GNN te dit *où le graphe encode le sensible*. Conséquence opérationnelle :

- Sur les axes où $r(s) \approx 0$ (le graphe ignore l'attribut), un post-process sur les sorties (DPT/EOT) suffit — l'embedding ne porte pas le signal sensible spécifiquement, tout se règle au niveau des prédictions.
- Sur les axes où $r(s)$ est élevé (le graphe amplifie l'attribut), il faut aussi nettoyer les embeddings (INLP) en plus des seuils. Sinon le sensible reste latent dans la représentation et fuit dans tout downstream.

Sur Pokec-z, ça veut dire : **DPT@gender** suffit pour `gender` ($r \approx 0$), mais `region` ($r = 0.9$) nécessite la chaîne **INLP+DPT** pour vraiment être traité.

4. Finding 3 — ULTIMATE composite : 5 axes simultanés mais coût F1 prohibitif

Pour traiter gender, region, age_group et leurs intersections **simultanément**, on encode l'attribut composite ($gender \times age_group \times region$) à 12 cellules et on applique INLP_composite + DPT_composite dessus.

Le pipeline ULTIMATE atteint le chance level (leakage ≈ 0.50) sur les 5 axes simultanément, y compris $gender \times age_group$ et $gender \times region$. Aucune autre méthode de notre toolbox n'y arrive — INLP+DPT mono-axe laisse fuiter sur les axes croisés ($gender \times age$ 0.85, $gender \times region$ 0.73).

Mais le coût F1 sur GraphSAGE est prohibitif. GraphSAGE+ULTIMATE chute à $F1=0.59$ (–35 pp vs baseline 0.94).

Mécaniquement : les embeddings GraphSAGE sont saturés par l'homophilie region (cohérent avec $r(region) = 0.9$) ; INLP composite, en supprimant les directions encodant les 12 cellules, supprime aussi la majorité du signal utile pour prédire y . La représentation s'effondre.

Conséquence pratique : ULTIMATE composite est *correct* au sens fairness (chance level partout) mais *inutilisable* en production sur un GNN homophile. Pour un cas réel multi-axes, il faut soit accepter un compromis sur le nombre d'axes traités simultanément (rester en mono-axe INLP+DPT), soit utiliser un encodeur dont les embeddings ne sont pas saturés par l'attribut sensible dominant — au-delà du périmètre des méthodes fairness-on-graphs étudiées ici.

Multi-seed [3, 7, 21, 42, 99] confirme la stabilité du finding : ΔDP gender ULTIMATE = 0.006 ± 0.005 , leakage $\approx 0.50 \pm 0.01$, F1 collapse stable.

5. Compromis perf ↔ équité ↔ robustesse

Perf vs équité. Le coût en F1 dépend du périmètre de fairness :

- Mono-axe simple (DPT ou EOT seul) : <0.5 pp de F1, une métrique réglée.
- Mono-axe combiné (INLP+DPT) : ~0.5 pp de F1, ΔDP et leakage réglés.
- Multi-axes composite (ULTIMATE) : 35 pp de F1 sur GraphSAGE — prohibitif. Le bénéfice (chance level sur 5 axes) ne compense pas la perte d'utilité.

Pas de free-lunch intersectionnel. DPT@gender seul atteint ΔDP gender = 0.019 mais laisse ΔDP $gender \times age_group$ à 0.085. C'est l'effet *whack-a-mole* prédit par l'argument intersectionnel de Crenshaw (1989). Pour traiter les axes croisés, il faut explicitement construire l'attribut composite et calibrer dessus, à charge de payer le coût associé.

Robustesse. La chaîne post-hoc préserve la robustesse héritée du modèle de base parce qu'elle ne modifie pas l'encoder. GraphSAGE reste robuste à un bruit features $\sigma \leq 0.3$ et à un edge drop $\leq 30\%$ (mesures issues du repo amont) avant comme après INLP+DPT. Avantage non-trivial sur l'in-training fairness, qui modifie l'encoder et peut dégrader sa robustesse de façon imprévue.

6. Limites

Limite philosophique. Les métriques de fairness encodent toutes une position normative implicite : $\Delta DP=0$ incarne l'anti-classification stricte, $\Delta EO=0$ incarne une méritocratie conditionnée à la vérité, la calibration par groupe assume que les écarts marginaux sont OK. Le théorème d'incompatibilité montre qu'on ne peut pas les satisfaire toutes à la fois. Notre toolbox fournit les outils, elle ne tranche pas le débat normatif.

Importation culturelle des catégories. La fairness ML hérite des catégories US des années 60 (gender, race binaires) et notre dataset les reproduit en réduisant gender et region à 0/1 sans documentation sémantique (Hoffmann 2019 ; Hanna et al. 2020). Le subset FairGNN code spoken_languages via 8 indicateurs binaires tous internationaux ou langue majoritaire ; le hongrois, le tchèque et le romani sont absents alors que le SNAP original les encode en texte libre. Conséquence : la littérature fairness-on-graphs travaille sur un subset structurellement aveugle aux axes ethniques slovaques.

Limites techniques. La garantie d'invariance d'INLP n'est valide que contre un classifieur linéaire ; un MLP probe non-linéaire pourrait recouvrir du signal résiduel. Le discriminateur FairGNN est binaire dans la formulation standard de Dai & Wang ; pour débaiser age_group (3 classes) en in-training il faudrait redimensionner la tête de discriminateur, non implémenté.

Pour conclure. Notre toolbox montre qu'on peut traiter la fairness sur un ou deux axes à coût d'utilité quasi-nul : DPT règle ΔDP , INLP+DPT règle ΔDP et leakage simultanément, à 0.5 pp de F1 près. Mais dès qu'on essaie de couvrir plus d'axes en même temps (composite multi-axes), la projection détruit suffisamment de signal utile pour que l'utilité s'effondre — sur GraphSAGE, la chaîne ULTIMATE perd 35 pp de F1 pour gagner le chance level sur 5 axes. **Faire de la fairness, c'est faire des choix** : quelle métrique privilégier, quels axes traiter, à quel coût d'utilité, sur quelle population (gender ? region ? un axe ethnique absent du dataset ?). Chaque choix encode une position normative. Et la question méta-éthique reste ouverte : *quis custodiet ipsos custodes ?* — qui dira que les choix qu'on fait pour rendre le modèle équitable sont eux-mêmes équitables ?

Annexes

A.1 Outils d'IA

Assistance algorithmique pour la migration pandas → polars, l'intégration des modules INLP / calibration / reweighting, le portage de FairGNN canonical (two-optimizer alternating depuis le repo Dai-Wang 2021), et la rédaction. Code revu, testé, exécuté par les auteurs.

A.2 Références

- Dai, E. & Wang, S. (2021). *Say No to the Discrimination — Learning Fair Graph Neural Networks with Limited Sensitive Attribute Information*. WSDM. — méthode FairGNN.
- Hardt, M., Price, E. & Srebro, N. (2016). *Equality of Opportunity in Supervised Learning*. NeurIPS. — DPT / EOT.
- Ravfogel, S. et al. (2020). *Null It Out — Guarding Protected Attributes by Iterative Nullspace Projection*. ACL. — INLP.
- Newman, M. E. J. (2003). *Mixing Patterns in Networks*. — coefficient d'assortativité utilisé pour $r(s)$.
- Chouldechova, A. (2017) ; Kleinberg, J. et al. (2017). Théorèmes d'incompatibilité entre métriques de fairness.
- Crenshaw, K. (1989). *Demarginalizing the Intersection of Race and Sex*. — argument intersectionnel.
- Hoffmann, A. L. (2019). *Where Fairness Fails — Data, Algorithms, and the Limits of Antidiscrimination Discourse*. — meta-critique de la fairness ML.

A.3 Comparaison méthodes × axe gender (Pokey-z, seed=42)

Source : results/metrics/comparison_full.csv.

Modèle	Acc	F1	ΔDP	ΔEO	Leakage
GraphSAGE	0.9383	0.9381	0.0429	0.0231	0.8120
GraphSAGE+Resampling	0.9383	0.9381	0.0423	0.0229	0.8109
GraphSAGE+FairDrop	0.9386	0.9384	0.0442	0.0253	0.8250
FairGNN canonical (two-opt, multi-seed μ)	0.937	0.937	0.030	0.014	0.828
GraphSAGE+EOT@gender	0.9393	0.9392	0.0191	0.0001	0.8120
GraphSAGE+DPT@gender	0.9393	0.9392	0.0191	0.0220	0.8120
GraphSAGE+INLP@gender	0.9317	0.9316	0.0428	0.0243	0.5726
GraphSAGE+INLP+DPT@gender	0.9320	0.9319	0.0032	0.0078	0.5726
GraphSAGE+ULTIMATE composite	0.6155	0.5915	0.0090	0.0248	0.4996

A.4 Comparaison méthodes × axe region (Pokey-z, seed=42)

Source : results/metrics/comparison_full.csv et results/metrics/fairgnn_on_region.csv.

Modèle	Acc	F1	ΔDP region	ΔEO region	Leakage region
GraphSAGE	0.9383	0.9381	0.0532	0.0042	0.6411
FairGNN canonical (adv=gender, two-opt μ)	0.937	0.937	0.043	0.018	0.821
FairGNN canonical (adv=region, two-opt μ)	0.938	0.938	0.033	0.006	0.764 ← <i>augmente</i>
GraphSAGE+DPT@region	0.9392	0.9390	0.0246	0.0222	0.6411
GraphSAGE+INLP@region	0.9336	0.9335	0.0487	0.0035	0.5237
GraphSAGE+INLP+DPT@region	0.9323	0.9322	0.0200	0.0219	0.5237
GraphSAGE+ULTIMATE composite	0.6155	0.5915	0.0122	0.0343	0.4959

A.5 ULTIMATE composite — un seul fit règle 5 axes (Pokey-z, seed=42)

Une seule chaîne INLP_composite + DPT_composite calibrée sur l'attribut joint à 12 cellules ramène le leakage **simultanément** au chance level (~0.50) sur les 5 axes — y compris les intersections.

Modèle	Attribut	ΔDP	ΔEO	AUC-gap	Leakage
GraphSAGE+ULTIMATE (Acc=0.616, F1=0.592)	gender	0.0090	0.0248	0.0085	0.4996
	region	0.0122	0.0343	0.0103	0.4959
	age_group	0.0304	0.0161	0.0324	0.5049
	gender × age	0.0534	0.0371	0.0532	0.4983
	gender × region	0.0405	0.0687	0.0388	0.4983

Coût : F1 = 0.59 sur GraphSAGE (−35 pp vs baseline). Le gain de fairness intersectionnelle ne compense pas la perte d'utilité — la chaîne reste un outil d'analyse, pas de production.