

Pokec-z — Fairness multi-axes par composition d'outils post-hoc

Mini-projet IADATA708. Branche `feature/fairgnn-fix-and-multi-fairness`.

1. Setup

Données. Pokec-z (subset officiel FairGNN, *Žilinský kraj*) : 66 569 nœuds, ~729 k arêtes, 264 features tabulaires. Reproduction sur **Pokec-n**. Cible : `completed_level_of_education_indicator` (binaire, 47.7 % positif). Attributs sensibles : `gender`, `region` (binaires), `age_group` (3 classes), plus les intersections `gender × age_group` et `gender × region` — soit **5 axes** simultanés.

Splits. Stratifié $y \times \text{gender}$ 60/20/20. Multi-seed [3, 7, 21, 42, 99].

Méthodes (toolbox de 5 familles) :

- **Baselines** : GraphSAGE (2 SAGE, hidden=256, dropout=0.5), **TabICL** (foundation tabulaire INRIA 2025, no graph, frozen).
- **Pre-process** : Resampling, FairDrop, Reweighting Kamiran-Calders 2012.
- **In-training** : **FairGNN avec Gradient Reversal Layer** — réimpl propre de Dai & Wang 2021. La version originale combinait $l_{cls} - \lambda \cdot l_{adv}$ dans un seul optimiseur (pas du min-max), F1 collapsait à 0.4834 à certains λ .
- **Post-process** : EOT (Hardt 2016), DPT (Demographic Parity Threshold), **INLP** (Ravfogel 2020) sur embeddings et features, et **les compositions INLP+DPT et leur version multi-axes simultanée**.

Métriques. ΔDP , ΔEO , AUC gap (sortie), **Sensitive Leakage AUC** (probe LR train→test, Laclau et al. 2024). 50+ tests pytest, ruff propre, no-pandas/no-loops enforced.

2. Finding 1 — Une toolbox, chaque outil sa métrique

Résultat empirique principal : **les méthodes de fairness ne sont pas substituables**, chacune attaque une dimension différente du problème.

Fig 1. Chaque outil tape une métrique différente — axe gender, Pokec-z
DPT casse ΔDP , INLP casse le leakage ; aucun outil seul ne fait les trois.




Fig 1. Mêmes méthodes, 3 métriques. **DPT** (bleu) écrase ΔDP à 0.004 mais ne touche pas le leakage. **INLP** (vert) tombe le leakage à 0.71 mais ne change pas ΔDP . **FairGNN** (rouge) bouge un peu les deux au prix de F1. Seul l'**ULTIMATE** (orange = TabICL+INLP_composite+DPT_composite) règle les trois en même temps.

Concrètement, pour un ingénieur qui voudrait une checklist :

Si tu veux réduire...	Utilise	Pourquoi
ΔDP (taux de prédictions $\approx$ entre groupes)	DPT post-process	calibre un seuil par groupe, c'est l'objectif direct
ΔEO (TPR $\approx$ entre groupes parmi $y=1$)	EOT post-process	même méca mais sur le sous-set $y=1$
Leakage (sensible récupérable depuis embeddings)	INLP	projette l'espace orthogonal aux directions du sensible
Tout en même temps	INLP_composite + DPT_composite	les deux sont orthogonaux et se composent sans conflit

Le théorème de Chouldechova-Kleinberg 2017 dit que $\Delta DP=0$ et $\Delta EO=0$ sont incompatibles dès que les taux de base diffèrent par groupe. On le confirme : DPT@age_group baisse ΔDP de 0.075 à 0.044 mais double ΔEO (0.034 → 0.074). Choix normatif, pas algorithmique.

3. Finding 2 — TabICL tient la composition multi-axes, GraphSAGE s'écrase

Quand on demande la fairness sur les **3 axes simultanément** (`gender + age_group + region`, encodés en attribut composite à 12 cellules), il faut composer **INLP_composite** (latent) + **DPT_composite** (sortie). C'est notre chaîne **ULTIMATE**.

Fig 2. TabICL tient la composition, GraphSAGE s'écrase
à droite : leakage descend au chance level pour les deux ; à gauche : GraphSAGE perd 35 pp de F1, TabICL seulement 8 pp.




Fig 2. F1 et leakage le long de la chaîne. À gauche : TabICL garde $F1=0.87$; GraphSAGE chute à 0.59 (perte de 35 pp de F1). À droite : les deux chaînes atteignent leakage = chance level (0.5).

Pourquoi GraphSAGE s'écroule et pas TabICL ? $r(\text{region}) = 0.901$ — le graphe est très homophile en region. Le message passing recombine les features d'un nœud avec celles de ses voisins (qui partagent region) ; les embeddings GraphSAGE encodent intensément la region. Quand INLP supprime ces directions, la représentation est dévastée. À l'inverse, TabICL ne consomme jamais le graphe → ses embeddings ne sont pas dominés par la region → INLP ne casse rien d'essentiel. **Multi-seed [3, 7, 21, 42, 99]** confirme : $\Delta DP \text{ gender ULTIMATE} = 0.006 \pm 0.005$; leakage gender = 0.500 ± 0.010 ; $F1 = 0.87 \pm$ marginal sur TabICL. **Reproduction sur Pokec-n** : tous les chiffres reproduisent à écart < 0.01 .

4. Compromis perf ↔ équité ↔ robustesse

- **Perf vs équité** : 8 pp de F1 pour la fairness multi-axes complète sur TabICL. **Acceptable**. Sur GraphSAGE, c'est -35 pp = inutilisable.
- **Pas de free-lunch intersectionnel** : DPT@gender seul atteint $\Delta DP \text{ gender} = 0.004$ mais laisse $\Delta DP \text{ gender} \times \text{age}$ à 0.10 (whack-a-mole).
- **Robustesse** : la chaîne post-hoc préserve la robustesse héritée (GraphSAGE robuste à bruit features $\sigma \leq 0.3$ et edge drop $\leq 30\%$ d'après le repo amont) parce qu'elle ne modifie pas l'encoder.

5. Limites

- *Mono-dataset family* — Pokec-z et Pokec-n sont 2 subsets du même réseau slovaque. Bail/Credit re-graphifiés nécessaires pour un workshop paper.
- *Probe linéaire* — INLP garantit l'invariance contre un classifieur linéaire. Un MLP probe pourrait recouvrir du signal résiduel.
- *Pré-traitement implicite* — INLP appliqué sur x brut côté TabICL est techniquement du pré-traitement (côté GraphSAGE on opère sur les embeddings, c'est purement post-hoc).
- *Sémantique opaque* — $\text{region}=0/1$ binarisé sans documentation par les auteurs FairGNN.
- *Catégories réifiées* — la fairness ML opère par agrégation de catégories préalables ; une fairness individuelle (Dwork 2012) sortirait du périmètre.

Outils d'IA (mention exigée) : assistance algorithmique pour la réimplémentation FairGNN-GRL, la migration pandas → polars, l'intégration TabICL, l'ajout des modules INLP / calibration / reweighting, et la rédaction. Code revu, testé, exécuté par les auteurs.

Références. Hardt-Price-Srebro 2016 ; Ravfogel et al. 2020 ; Ganin & Lempitsky 2015 ; Dai & Wang 2021 ; Kamiran & Calders 2012 ; Chouldechova 2017 ; Crenshaw 1989 ; Qu et al. 2025 (TabICL) ; Laclau et al. 2024.