

Pokec-z — Quel axe sensible faut-il fairner ?

Mini-projet IADATA708. Branche `feature/fairgnn-fix-and-multi-fairness`.

1. Setup

Données. Pokec-z (subset officiel FairGNN, *Žilinský kraj*) : 66 569 nœuds, ~729 k arêtes, 264 features tabulaires. Reproduction sur **Pokec-n**. Cible : `completed_level_of_education_indicator` (binaire, 47.7 % positif). Attributs sensibles : `gender`, `region` (binaires), `age_group` (3 classes), plus les intersections `gender × age` et `gender × region` — soit **5 axes** simultanés.

Splits. Stratifié $y \times \text{gender}$ 60/20/20. Multi-seed [3, 7, 21, 42, 99].

Méthodes (toolbox de 5 familles) : GraphSAGE, **TabICL** (foundation tabulaire, no graph), Resampling, FairDrop, Reweighting Kamiran-Calders, **FairGNN** (Dai & Wang 2021) — méthode adversariale ; on a remplacé l'implémentation amont par une variante avec **Gradient Reversal Layer** pour stabiliser l'entraînement adversarial, **EOT/DPT** (Hardt 2016), **INLP** (Ravfogel 2020), et la chaîne composite multi-axes **INLP_composite + DPT_composite**.

Métriques. ΔDP , ΔEO , AUC gap, **Sensitive Leakage AUC** (probe LR train→test, Laclau et al. 2024). 50+ tests pytest, ruff propre, no-pandas/no-loops enforced.

2. Finding 1 — Une toolbox, chaque outil sa métrique

Premier résultat empirique : **les méthodes de fairness ne sont pas substituables**. Chaque famille attaque une partie spécifique du problème, et il faut souvent en composer plusieurs pour traiter les trois métriques en même temps.

Fig 1. Chaque outil tape une métrique différente — axe gender, Pokec-z
DPT casse ΔDP , INLP casse le leakage ; aucun outil seul ne fait les trois.




Fig 1. Mêmes méthodes, 3 métriques. **DPT** (bleu) écrase ΔDP à 0.004 mais ne touche pas le leakage. **INLP** (vert) tombe le leakage mais ne change pas ΔDP . **FairGNN** (rouge) bouge un peu les deux au prix de F1. Seul l'**ULTIMATE** (orange = TabICL+INLP_composite+DPT_composite) règle les trois en même temps.

Pour un ingénieur qui voudrait une checklist :

Si tu veux réduire...	Utilise	Pourquoi
ΔDP (taux $\approx$ entre groupes)	DPT post-process	calibre un seuil par groupe
ΔEO (TPR $\approx$ entre groupes parmi $y=1$)	EOT post-process	même méca, sur le sous-set $y=1$
Leakage (sensible récupérable depuis embeddings)	INLP	projette l'espace orthogonal au sensible
Tout en même temps, sur plusieurs axes	INLP_composite + DPT_composite	les deux sont orthogonaux et se composent sans conflit

Le théorème de Chouldechova-Kleinberg (2017) confirme l'incompatibilité de $\Delta DP=0$ et $\Delta EO=0$ dès que les taux de base diffèrent : **DPT@age_group** baisse ΔDP de 0.075 à 0.044 mais double ΔEO . Choisir une métrique = choisir une éthique.

3. Finding 2 — Quel axe fairner ? Celui que le graphe amplifie, pas celui qu'on attend

Le second résultat est méthodologique et il **inverse l'intuition initiale**. On a passé l'essentiel du projet à fairner `gender` (axe protégé reconnu). Mesurer le coefficient d'assortativité de Newman (2003) sur les 3 axes sensibles révèle qu'on s'est trompé d'axe :

Axe	$r(s)$	Interprétation
gender	-0.046	graphe quasi-aléatoire vs gender → message passing n'amplifie rien
age_group	+0.352	légère homophilie générationnelle
region	+0.901	graphe massivement homophile en region

$r(\text{region}) = 0.9$ signifie que ~90 % des arêtes connectent deux personnes de la même région : Pokec-z est en pratique un graphe de régions, faiblement inter-connecté. Un GNN dessus va amplifier cette structure dans ses embeddings — c'est *exactement* le scénario où les méthodes fairness-on-graphs sont conçues pour intervenir. Or on a appliqué FairGNN avec l'adversaire sur `gender` (où il n'y a rien à attaquer) au lieu de `region` (où il y aurait quelque chose à faire).

FairGNN avec adversaire sur le mauvais axe. Avec adversaire sur `gender`, F1 chute à 0.853 (-9 pp) sans réel bénéfice fairness sur `region` (leakage `region` passe de 0.641 à **0.666** — *augmente*).

FairGNN avec adversaire sur region (multi-seed Pokec-z, λ choisi par val) tient F1 à **0.93** — quasi le baseline GraphSAGE 0.938. L'adversaire trouve une cible utile et l'encoder ne paie pas le coût d'un débiaisage illusoire.

Mais surtout, post-process suffit. Les méthodes simples sur axe `region` règlent le problème à coût F1 quasi-nul :

Méthode	F1	ΔDP region	Leakage region
TabICL baseline	0.9484	0.0493	0.6208
TabICL+DPT@region	0.9467	0.0168	0.6208
TabICL+INLP@region	0.9426	0.0547	0.5574
TabICL+INLP+DPT@region	0.9433	0.0192	0.5574
FairGNN($\lambda=5$, adv=gender)	0.8532	0.0729	0.6661

DPT@region halve ΔDP en perdant **0.2 pp de F1**. INLP+DPT@region atteint $\Delta DP \approx 0.02$ ET leakage ≈ 0.56 en perdant **0.5 pp de F1**. Aucune raison d'engager un FairGNN à 200 epochs quand un post-process à 30 lignes fait mieux.

La règle pratique qui en sort : mesurer $r(s)$ avant tout entraînement GNN. Si $r(s)$ est élevé sur un axe, c'est cet axe qu'il faut fairner — indépendamment de quel axe on attendait normativement. Si $r(s)$ est faible sur tous les axes pertinents, le graphe ne contribue ni au signal ni au biais, et un foundation tabulaire + post-process est presque toujours le bon choix.

4. Finding 3 — ULTIMATE composite : un seul fit règle les 5 axes

Pour traiter gender, region, age_group, et leurs intersections *simultanément*, on encode l'attribut composite (gender $\times$ age_group $\times$ region, 12 cellules) et on applique INLP_composite + DPT_composite dessus :

Fig 2. TabICL tient la composition, GraphSAGE s'écroule
à droite : leakage descend au chance level pour les deux ; à gauche : GraphSAGE perd 35 pp de F1, TabICL seulement 8 pp.




Fig 2. F1 et leakage le long de la chaîne. À gauche : TabICL garde F1=0.87 ; GraphSAGE chute à 0.59 (perte 35 pp). À droite : leakage moyen descend à 0.50 (chance) sur les deux.

Le pipeline ULTIMATE atteint **leakage ≈ 0.50 sur les 5 axes simultanément** ($\Delta DP < 0.05$ partout) au prix de 8 pp de F1 sur TabICL. GraphSAGE+ULTIMATE s'écroule (F1 $\rightarrow 0.59$), confirmation indirecte que ses embeddings sont saturés en region (cohérent avec $r(\text{region}) = 0.9$).

Multi-seed [3, 7, 21, 42, 99] $\times$ Pokec-z/n confirme la stabilité : ΔDP gender ULTIMATE = 0.006 ± 0.005 , F1 = 0.87 dispersion marginale, reproduction Pokec-n à < 0.01 près.

5. Compromis perf $\leftrightarrow$ équité $\leftrightarrow$ robustesse

Perf vs équité. Le coût dépend de l'axe choisi : 0.5 pp F1 sur TabICL+INLP+DPT@region ; 8 pp F1 sur ULTIMATE composite (5 axes) ; 35 pp F1 sur GraphSAGE+ULTIMATE (graphe homophile saturé). Avant de payer le coût de la chaîne complète, vérifier qu'on a vraiment besoin des 5 axes.

Pas de free-lunch intersectionnel. DPT@gender seul atteint ΔDP gender = 0.004 mais laisse ΔDP gender $\times$ age_group à 0.10 — voire 0.154 sur FairGNN où la marginale gender est à 0.009. Pour traiter les axes croisés, il faut explicitement construire l'attribut composite et calibrer dessus.

Robustesse. La chaîne post-hoc préserve la robustesse héritée du modèle de base parce qu'elle ne modifie pas l'encoder. GraphSAGE reste robuste à un bruit features $\sigma \leq 0.3$ et à un edge drop $\leq 30\%$ avant comme après INLP+DPT. Avantage non-trivial sur l'in-training fairness, qui modifie l'encoder et peut dégrader sa robustesse de façon imprévue.

6. Limites

Limite philosophique. Les métriques de fairness encodent toutes une position normative implicite : $\Delta DP=0$ incarne l'anti-classification stricte, $\Delta EO=0$ incarne une méritocratie conditionnée à la vérité, la calibration par groupe assume que les écarts marginaux sont OK. Choisir une métrique, c'est choisir une éthique — et le théorème d'incompatibilité montre qu'on ne peut pas toutes les satisfaire à la fois. Notre toolbox fournit les outils, elle ne tranche pas le débat normatif.

Importation culturelle des catégories. La fairness ML hérite des catégories du civil rights act US des années 60 (gender, race binaires) et notre dataset les reproduit en réduisant gender et region à 0/1 sans documentation sémantique (Hoffmann 2019 ; Hanna et al. 2020). Concrètement, le subset FairGNN code spoken_languages via 8 indicateurs binaires (anglais, allemand, russe, français, espagnol, italien, slovaque, japonais), tous internationaux ou langue majoritaire. Le hongrois (madarsky), le tchèque (cesky) et le romani sont absents, alors que le dataset SNAP original les encode en texte libre. La curation a probablement filtré ces langues parce qu'elles ont un taux d'occurrence faible dans Žilinský kraj (0.13 % d'hongrois, peu de gitans), mais le résultat est que toute la littérature fairness-on-graphs travaille sur un subset structurellement aveugle aux axes ethniques.

Limites techniques. La garantie d'invariance d'INLP n'est valide que contre un classifieur linéaire ; un MLP probe non-linéaire pourrait recouvrir du signal résiduel. Le discriminateur FairGNN est binaire dans la formulation standard de Dai & Wang ; pour fairner age_group (3 classes) en in-training il faudrait redimensionner la tête de discriminateur, non implémenté. Une variante exploratoire **ULTIMATE-LATENT** (INLP appliqué dans TabICLCache.row_repr puis ré-injecté dans icl_predictor) gagne 1.8 pp F1 sur Pokec-z mais s'effondre sur 3/5 seeds Pokec-n : pas Pareto-dominante, pipeline x-brut reste préféré (chiffres en annexe A.5).

Limite de généralisation. Pokec-z et Pokec-n sont deux subsets du même réseau slovaque, et la cible completed_level_of_education_indicator est faiblement homophile en gender. Nos conclusions sur "le graphe amplifie peu sur ce dataset" sont conditionnelles à cette propriété.

Pour conclure. Le choix d'axe sensible est probablement la limite la plus structurante du projet. Dans un contexte d'Europe centrale, et particulièrement en Slovaquie, l'axe ethnique — minorité hongroise et surtout minorité gitane — est beaucoup plus prévalent comme source de discrimination effective que l'axe du sexe sur lequel on a passé la majeure partie de l'étude. Logement, accès à l'éducation, embauche : c'est sur ces axes-là que les disparités mesurables sont les plus fortes en Slovaquie. Le verrou principal n'est plus algorithmique — il est en amont, au niveau de la collecte et de la curation des données. Tant qu'un dataset fairness-on-graphs slovaque sans label ethnique reste le standard de la littérature, l'évaluation des méthodes restera détachée des axes de discrimination qui comptent vraiment dans le pays d'origine de la donnée.

Annexes

A.1 Outils d'IA

Assistance algorithmique pour la réimplémentation FairGNN-GRL, la migration pandas → polars, l'intégration TabICL, l'ajout des modules INLP / calibration / reweighting, et la rédaction. Code revu, testé, exécuté par les auteurs.

A.2 Références

Hardt-Price-Srebro 2016 ; Ravfogel et al. 2020 ; Ganin & Lempitsky 2015 ; Dai & Wang 2021 ; Kamiran & Calders 2012 ; Chouldechova 2017 ; Crenshaw 1989 ; Hoffmann 2019 ; Hanna et al. 2020 (FAccT) ; Newman 2003 ; Qu et al. 2025 (TabICL) ; Laclau et al. 2024.

A.3 FairGNN — adversaire sur axe gender vs region (multi-seed Pokec-z/n)

Source : results/metrics/fairgnn_on_region.csv. Multi-seed [3, 7, 21, 42, 99] × Pokec-z/n. Validation empirique de l'effet du choix d'axe adversarial.

Adversaire	F1	ΔDP region	Leakage region
gender ($\tau \approx 0$, axe inutile)	0.853	0.073	0.666
region ($\tau = 0.9$, axe homophile)	0.937	0.035	0.761
post-process TabICL+DPT@region	0.947	0.017	0.621
post-process TabICL+INLP+DPT@region	0.943	0.019	0.557

Lecture : changer l'adversaire de gender (inutile) à region (homophile) **récupère 8 pp de F1** (0.85 → 0.94) — confirmation que l'axe doit être bien choisi. **Mais ΔDP région n'est réduit que modérément**, et le **leakage région augmente** (l'encoder apprend à tromper l'adversaire MLP de FairGNN sans supprimer le signal qu'un probe LR peut récupérer). **Post-process simple bat FairGNN sur les 3 métriques même sur le bon axe** : DPT@region donne un meilleur ΔDP, INLP+DPT@region un meilleur leakage, à un meilleur F1. *Conclusion renforcée du papier original* : post-process Pareto-domine in-training adversariale *quel que soit l'axe choisi*.

A.4 Comparaison méthodes × axe region (Pokec-z, seed=42)

Source : results/metrics/comparison_full.csv. Acc et F1 sont identiques par modèle ; ΔDP/ΔEO/Leakage évalués sur l'axe region.

Modèle	Acc	F1	ΔDP region	ΔEO region	Leakage region
GraphSAGE	0.9383	0.9381	0.0532	0.0042	0.6411
GraphSAGE+Resampling	0.9383	0.9381	0.0524	0.0016	0.6404
GraphSAGE+FairDrop	0.9386	0.9384	0.0546	0.0068	0.6325
FairGNN ($\lambda=5$, adv=gender)	0.8533	0.8532	0.0729	0.0188	0.6661
TabICL	0.9486	0.9484	0.0493	0.0014	0.6208
GraphSAGE+EOT@region	0.9378	0.9377	0.0591	0.0096	0.6411
TabICL+EOT@region	0.9490	0.9488	0.0565	0.0074	0.6208
GraphSAGE+DPT@region	0.9392	0.9390	0.0246	0.0222	0.6411
TabICL+DPT@region	0.9469	0.9467	0.0168	0.0312	0.6208
GraphSAGE+INLP@region	0.9336	0.9335	0.0487	0.0035	0.5237
TabICL+INLP@region	0.9428	0.9426	0.0547	0.0057	0.5574
GraphSAGE+INLP+DPT@region	0.9323	0.9322	0.0200	0.0219	0.5237
TabICL+INLP+DPT@region	0.9435	0.9433	0.0192	0.0283	0.5574
GraphSAGE+ULTIMATE (composite)	0.6155	0.5915	0.0122	0.0343	0.4959
TabICL+ULTIMATE (composite)	0.8659	0.8657	0.0174	0.0434	0.4950

A.5 ULTIMATE composite — un seul fit règle TOUT (Pokec-z, seed=42)

Source : results/metrics/comparison_full.csv. Une seule chaîne INLP_composite + DPT_composite à 12 cellules calibrée sur l'attribut joint ($gender \times age_group \times region$) ramène le leakage **simultanément** au chance level (~0.50) sur les 5 axes.

Modèle	Attribut	ΔDP	ΔEO	AUC-gap	Leakage
GraphSAGE+ULTIMATE (Acc=0.616, F1=0.592)	gender	0.0090	0.0248	0.0085	0.4996
	region	0.0122	0.0343	0.0103	0.4959
	age_group	0.0304	0.0161	0.0324	0.5049
	gender × age	0.0534	0.0371	0.0532	0.4983
	gender × region	0.0405	0.0687	0.0388	0.4983
TabICL+ULTIMATE (Acc=0.866, F1=0.866)	gender	0.0134	0.0008	0.0018	0.5059
	region	0.0174	0.0434	0.0143	0.4950
	age_group	0.0196	0.0437	0.0294	0.4790
	gender × age	0.0494	0.0638	0.0448	0.4995
	gender × region	0.0366	0.0711	0.0196	0.4951